

PROJET 4 — Optimisation de l'Efficacité au Sol : Prédiction du Taxi-Out

Dataset :

<https://www.kaggle.com/datasets/ahmedelsayedrashad/airline-on-time-performance-data>

Objectif du projet : Prédire le temps de "Taxi-Out" pour chaque vol. Ce paramètre est crucial pour la planification des créneaux de décollage et la réduction de la consommation de carburant au sol.

PARTIE 1 — Machine Learning

Tâches ML :

- Prétraitement des données
- Feature Engineering :
 - Pression de l'aéroport : Calculer le nombre de départs prévus dans la même fenêtre de 15 ou 30 minutes.
 - Conditions météo : Intégrer les indicateurs de visibilité et de vent (présents dans les champs de cause de retard météo).
 - Temporalité : Heure de pointe vs heure creuse, jour de la semaine.
- Modèles à appliquer :

Linear Regression

Random Forest

XGBoost / LightGBM (Régression sur le temps en minutes).

ElasticNet (pour identifier si certaines compagnies ou types d'avions ont un impact linéaire).

Évaluation :

MAE (Mean Absolute Error) : l'erreur moyenne en minutes.

RMSE : pour pénaliser les fortes erreurs de prédiction (critique pour la congestion).

Comparer erreurs selon :

- aéroport
- heure de pointe
- compagnie
- météo

PARTIE 2 — Deep Learning

Architectures proposées :

MLP (Multi-Layer Perceptron) Profond : Utilisation d'Entity Embeddings pour gérer les catégories à haute cardinalité (ex: codes d'aéroports, types d'appareils).

RNN / LSTM : Si l'on traite les données comme une série temporelle de congestion à l'échelle d'un aéroport spécifique (prédire le taxi-out du vol \$N\$ en fonction des délais observés sur les vols \$N-1\$ à \$N-10\$).

LivrablesDL :

- Analyse de l'importance des variables (Feature Importance vs SHAP values).
- Analyse heure de pointe vs creuse
- Analyse par aéroport
- Robustesse du modèle dans les cas suivants :
 - jours normaux
 - jours congestionnés
 - météo dégradée
- Comparaison DL vs Gradient Boosting

Le projet doit implémenter et documenter les éléments suivants :

- Gestion du Learning Rate : Utilisation d'un Scheduler (ex: ReduceLROnPlateau) pour adapter la vitesse d'apprentissage en fonction de la stagnation de la perte.
- Stabilité & Généralisation :
 - Minibatch Size : Étude comparative de l'impact de la taille des batchs sur la stabilité des gradients.
 - Dropout : Application rigoureuse pour briser les co-dépendances neuronales et réduire l'overfitting.

Contrôle de l'Entraînement :

- EarlyStopping : Arrêt automatique dès que la val_loss ne s'améliore plus (patience à définir).
- GridSearchCV / Optuna : Recherche systématique des meilleurs hyperparamètres pour le ML classique.

Analyse de Performance :

- Courbes d'apprentissage (Loss & Accuracy/MAE) comparant Train vs Validation.
- Comparaison avant/après tuning (Gain de performance réel).
- Analyse des résidus (Régression) ou Matrice de confusion/ROC-AUC (Classification).

A la fin de la réalisation du projet, aura les livrables suivants :

- Notebook ML + Notebook DL
- Pipeline automatique
- Rapport technique (15–20 pages)
- Présentation 10–12 min